# QSDD: Quantum Spin Drift Diffusion model

**정건우**

## Abstract

다수의 conditional diffusion model은 샘플링을 공유된 unconditional prior $p(x_T)$에서 시작하며, 조건 정보는 주로 reverse-time process에서 denoiser 입력(embedding/attention) 또는 guidance 형태로 주입된다(Ho et al.2020). 이 설계는 안정적이지만, 서로 다른 조건들이 동일한 terminal initialization을 공유함으로써 조건 간 path overlap이 구조적으로 길어지고, 조건 분리 부담이 reverse 과정 후반부로 밀릴 수 있다.

본 논문은 이 현상을 "조건 표현력 부족"이 아니라, **shared $p(x_T)$**가 강제하는 **terminal reference 공유**의 관점에서 재정식화한다. 공유 prior에서는 조건별 terminal mean이 사실상 동일(통상 0)해지며, 결과적으로 reverse 과정이 denoising과 조건 분리를 동시에 수행해야 한다. 특히 조건을 더 정밀하게 "조절"하거나(예: 혼합 비율/연속 제어), 조건 공간을 확장하려는 상황에서는 이 결합이 불리하게 작용할 수 있다.

이를 해결하기 위해, 우리는 조건을 reverse 입력 신호가 아니라 **noise conditional distribution $p(x_T \mid c)$**로 재배치하는 **Quantum Spin Drift Diffusion (QSDD)**를 제안한다. QSDD는 drift-augmented forward를

$$q(x_t \mid x_0, c) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\, r_t(c), \quad (1-\bar{\alpha}_t)I)$$

로 정의하여 terminal mean을

$$\mathbb{E}[x_T \mid c] = \sqrt{1-\bar{\alpha}_T}\, r_T(c)$$

로 **명시적으로 분리**한다. 여기서 $r_t(c)$는 **학습되는 임베딩이 아니라**, 사전 구성된 방향장 $\hat{u}$와 에너지 계수 $A$를 통해 **통제 가능한 제어 포트(control port)**로 설계될 수 있으며, 이는 ShiftDDPMs(Zhang et al.2023)와 같이 prior/trajectory를 변형하는 family에 속하면서도 "제어 가능성"을 전면에 둔 구성이다. 동시에 QSDD는 $\eta$-target($\eta = \epsilon + r_t(c)$) 학습과 **DDPM-equivalent $y$-world 정렬**을 통해 표준 DDPM reverse 업데이트(Ho et al.2020)와의 호환성을 유지한다. 마지막으로, Pauli/Dirac에서 영감을 받은 spinor parameterization을 도입하여 조건을 정규화된 상태 공간 위의 좌표로 표현함으로써, 향

후 다축 조건 및 **연속 제어**로의 자연스러운 확장 가능성을 제시한다.

.

## 1. Introduction

Diffusion model은 데이터를 점진적으로 noising하여 알려진 prior로 보내고, reverse-time에서 이를 복원하도록 학습함으로써 샘플을 생성한다(Ho et al.2020; Song et al.2021). Conditional generation에서는 조건을 denoiser 입력에 주입하거나 guidance로 조절하는 방식이 널리 사용되어 왔으며, class-conditional 및 text-conditional 설정에서 높은 성능을 달성해왔다(Dhariwal & Nichol.2021; Nichol et al.2021; Ho & Salimans.2022).

그러나 conditional diffusion의 주류 설계는 공통된 구조적 특성을 갖는다. 샘플링은 공유된 unconditional prior $p(x_T)$에서 시작하고, 조건은 주로 reverse-time conditioning으로 반영된다. 이때 서로 다른 조건은 terminal initialization을 공유하므로 조건 간 path overlap이 구조적으로 유지될 수 있으며, 조건 분리는 reverse 과정에서 후행적으로 형성되거나 강한 test-time 조향에 의존하게 된다. 문제는 reverse 과정 후반부가 세밀한 복원과 안정성이 동시에 요구되는 구간이라는 점에서, denoising과 조건 분리 부담이 결합될 경우 성능 저하나 불안정성을 유발할 수 있다는 것이다.

본 연구는 이 병목을 **shared prior가 강제하는 terminal reference 공유**로 해석한다. 공유 prior에서는 조건별 terminal mean이 동일해지는 경향이 있고, 그 결과 reverse 과정은 "복원"과 "trajectory separation"을 동시에 수행해야 한다. 즉, 조건부 생성의 핵심 병목을 reverse-time에서의 조건 주입 방식 자체가 아니라, **샘플링의 출발점(terminal distribution)의 공유 구조**에서 찾는다. 이를 생성 모델의 분해로 보면, 주류 방식은

$$p_\theta(x_{0:T} \mid c) = p(x_T) \prod_{t=1}^{T} p_\theta\,(x_{t-1} \mid x_t, c)$$

처럼 조건과 무관한 $p(x_T)$에서 시작하는 반면, QSDD는 조건이 **초기화 분포 자체를 규정**하는 방향으로 문제를 재배치한다.

이를 해결하기 위해 우리는 QSDD를 제안한다. QSDD의 핵심은 conditioning의 위치를 바꾸는 것이다. 조건을 reverse-time 입력 신호로 취급하는 대신, 조건이 noise conditional distribution $p(x_T \mid c)$를 규정하도록 재해석하고, drift-augmented forward를 통해 이를 구현한다:

$$q(x_t \mid x_0, c) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\, r_t(c),\ (1-\bar{\alpha}_t)I).$$

이에 따라 terminal 단계에서 $\mathbb{E}[x_T \mid c] = \sqrt{1-\bar{\alpha}_T}\, r_T(c)$가 되어, 조건 분리가 reverse 후반부에만 의존하지 않도록 유도한다. 또한 QSDD는 $\eta$-target($\eta = \epsilon + r_t(c)$)을 학습 대상으로 두고, DDPM-equivalent $y$-world 정렬을 통해 표준 DDPM reverse 업데이트(Ho et al.2020)와의 호환성을 유지한다. 즉, prior를 변형하는 계열(예: ShiftDDPMs)과 문제의식을 공유하되(Zhang et al.2023), QSDD는 **drift 방향 $\hat{u}$**와 에너지 계수 $A$를 통해 조건을 **명시적·통제 가능하게 지정**하고, 그 결과를 **DDPM 샘플러의 형태로 그대로 사용**할 수 있도록 정합성 프레임($\eta$-target, $y$-world)을 함께 제공하는 데 초점을 둔다.

또한 우리는 조건 공간을 단순한 discrete label의 집합으로 두지 않고, Pauli/Dirac-inspired spinor parameterization을 통해 조건을 정규화된 상태 공간 위의 좌표로 표현한다. 이는 단일 축(1D instantiation)을 넘어, 다축 조건 및 **연속 제어**로 자연스럽게 확장 가능한 표현을 제공하며, 본 논문의 noise-space conditioning 프레임워크와 결합될 때 "조건의 구조적 분리"와 "조건 공간의 확장성"을 동시에 목표로 한다.

**Contributions.**
(1) Conditional path overlap을 shared $p(x_T)$가 유도하는 terminal reference 공유 문제로 정식화하고, 이를 $\mathbb{E}[x_T \mid c]$관점에서 명시한다.
(2) 조건을 noise conditional distribution $p(x_T \mid c)$로 재배치하고, drift-augmented forward로 terminal mean을 분리하는 QSDD를 제안한다.
(3) $\eta$-target 및 DDPM-equivalent $y$-world 정렬을 통해 DDPM reverse 업데이트와의 호환성을 유지하면서 conditional structure를 train-time에 학습한다.
(4) Pauli/Dirac-inspired spinor parameterization을 제시하여 조건을 정규화된 상태 공간 위에서 좌표화하고, 다축 조건 및 연속 제어로의 확장 가능성을 제공한다.

## 2. Related Work

### 2.1 Diffusion / score-based generative models

DDPM은 고정된 forward noising으로 데이터를 단순한 prior(통상 표준 가우시안)로 보내고, reverse Markov chain을 학습하여 샘플을 생성하는 프레임워크를 제시했다(Ho et al., 2020). score-based 및 SDE 관점은 이를 연속시간 dynamics로 일반화하여 reverse-time sampling을 체계화한다(Song et al., 2021). shared prior는 설계를 단순화하지만, conditional setting에서는 서로 다른 조건이 동일한 terminal initialization을 공유하게 함으로써 조건 분리의 부담이 reverse-time으로 집중되는 구조적 병목이 발생할 수 있다.

### 2.2 Reverse-time conditioning and guidance

조건부 확산은 조건을 denoiser 입력에 주입하거나 guidance 항으로 조절하는 방식으로

발전해 왔다. classifier guidance는 class-conditional 합성에서 강력한 성능을 보였고 (Dhariwal & Nichol, 2021), classifier-free guidance는 외부 분류기 없이도 강력한 조향을 제공한다(Ho & Salimans, 2022). text-conditional diffusion에서도 guidance 기반 접근이 널리 사용되며, GLIDE는 대표적 사례이다(Nichol et al., 2021). 다만 이 계열은 대체로 shared $p(x_T)$위에서 reverse-time 방향 조절로 조건을 반영하므로, 조건 분리의 구조적 부담이 terminal prior 공유로부터 완전히 해소되지는 않는다.

### 2.3 Conditional forward / trajectory shifting

최근에는 조건을 reverse-time 입력에만 두지 않고, forward 과정 또는 trajectory 수준에서 조건 효과를 반영하려는 시도들이 보고되었다. 예를 들어 ShiftDDPMs는 조건에 따라 diffusion trajectory를 shift시키는 방식으로 conditional-forward를 구현한다(Zhang et al.2023). 이러한 접근은 shared $p(x_T)$기반의 reverse-only conditioning에서 발생할 수 있는 조건 간 overlap 문제를 완화하려는 흐름으로 이해할 수 있다.

본 연구의 QSDD 역시 prior/trajectory를 변형하는 conditional-forward family에 속하지만, **조건 효과를** drift $r_t(c)$로 명시화하고 이를 방향($\hat{u}$)과 강도($A$)로 분해 가능한 형태로 구성함으로써, 조건 제어를 모델 내부 임베딩 학습에 의존하지 않고 외부에서 통제 가능한 제어 포트로 취급할 수 있다는 점을 강조한다.

### 2.4 ODE/flow-based generation

PFGM은 augmented space에서 Poisson equation으로 유도된 vector field를 따라 deterministic ODE로 prior에서 데이터 분포로 매핑하는 접근을 제시했다(Xu et al., 2022). PFGM++는 diffusion과 flow 계열을 연결하는 관점을 확장한다(Xu et al., 2023). ODE/flow는 효율성 및 invertibility 측면에서 장점이 있으나, conditional control을 통합하려면 초기 분포 혹은 vector field 조건화를 추가로 설계해야 하며, diffusion의 stochastic reverse 구조가 제공하는 조건부 분기/다양성과의 정합을 확보하기 위해 별도 메커니즘이 요구될 수 있다.

### 2.5 Our positioning

요약하면, 주류 conditional diffusion은 shared $p(x_T)$위에서 reverse-time conditioning 또는 guidance로 조건을 반영해 왔고(Ho et al.2020; Ho & Salimans.2022), 최근에는 조건을 forward/trajectory로 이동시키는 conditional-forward 계열도 제안되었다(Zhang et al.2023). QSDD는 이 흐름과 문제의식을 공유하면서도, 다음과 같은 관점에서 모델을 재구성한다.

첫째, QSDD는 conditional generation의 구조적 병목을 "terminal reference 공유"로 정식화하고, 조건을 reverse 입력이 아니라 **noise conditional distribution $p(x_T \mid c)$**로 재배

치하여 **terminal mean** $\mathbb{E}[x_T \mid c]$분리를 직접 목표로 한다. 이때 조건 효과는 drift-augmented forward에서

$$q(x_t \mid x_0, c) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\, r_t(c), (1-\bar{\alpha}_t) I)$$

로 나타나며, terminal 단계에서 $\mathbb{E}[x_T \mid c] = \sqrt{1-\bar{\alpha}_T}\, r_T(c)$로 명시된다.

둘째, QSDD는 $\eta$-target 및 DDPM-equivalent $y$-world 정렬을 통해, prior/trajectory 변형이 포함된 구조에서도 **표준 DDPM reverse 업데이트와의 호환성**을 유지하는 정합성 프레임을 제공한다(Ho et al.2020). 즉, 조건 효과를 terminal/prior 측으로 이동시키면서도 샘플링 절차는 DDPM의 안정적인 형태를 그대로 레버리지한다.

셋째, QSDD의 instantiation에서는 drift $r_t(c)$를 방향장 $\hat{u}$와 강도 $A$로 분해하여, 조건 분리의 "방향"과 "세기"를 **통제 가능한 제어 포트**로 취급할 수 있다. 특히 $\hat{u}$를 데이터 통계로부터 고정(예: 도메인 평균 차)하고 $A$를 sweep 하는 구성은, **추가적인 조건 임베딩/별도 네트워크 학습 없이도**(즉, 별도의 conditioning module 없이) 분리 강도를 체계적으로 제어·분석할 수 있는 실용적 장점을 제공한다.

넷째, Pauli/Dirac-inspired spinor parameterization은 조건을 정규화된 상태 공간 위의 좌표로 표현하여, 단일 축(1D) 조건을 넘어 다축 조건 및 연속 제어로의 확장 가능성을 구조적으로 제공한다

## 3. Method

### 3.1 기존 형태의 DDPM: DDPM forward / reverse

우리는 데이터 $x_0 \sim p_{\text{data}}(x)$, timestep $t \in \{1, \dots, T\}$, noise $\epsilon \sim \mathcal{N}(0, I)$를 사용한다. DDPM의 분산 스케줄을 $\{\beta_t\}_{t=1}^{T}$라 하고 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{i=1}^{t} \alpha_i$로 정의한다.

DDPM(Ho et al., 2020)의 전방 과정은 다음과 같다.

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \epsilon \sim \mathcal{N}(0, I),$$

따라서, forward 분포는

$$q(x_t \mid x_0) = \mathcal{N}\left(\sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t) I\right).$$

reverse process는 학습된 denoiser(예: U-Net, ε-prediction 모델)$\epsilon_\theta(x_t, t)$)를 통해 $p_\theta(x_{t-1} \mid x_t)$를 가우시안으로 근사하고, $t = T \to 1$로 샘플링한다.

Reverse 과정은 모델 $p_\theta(x_{t-1} \mid x_t)$가 Gaussian을 예측하도록 두며, 통상 $\epsilon_\theta(x_t, t)$또는

$x_{0,\theta}(x_t, t)$를 통해 평균 $\mu_\theta$를 구성한다. (Ho et al., 2020)

### 3.2 QSDD: conditioning을 noise-space(=forward 분포)로 전환

#### 3.2.1 Drift-augmented forward process (이 곳에 block diagram 삽입 예정)

기존 conditional diffusion은 shared $p(x_T)$에서 출발하므로, 조건 분리는 reverse 조향으로 나중에 만들어진다. 반면 **QSDD**의 수식은 forward 수준에서부터 평균 이동이 조건에 종속되도록 설계하여, $t \approx T$의 terminal region에서 **조건별 분포 분리($p(x_T \mid c)$)**를 유도한다. 즉 conditioning을 입력 신호가 아니라 **noise conditional distribution**으로 재배치하는 구조이다.

QSDD의 forward는 다음과 같이 정의한다:

$$\boldsymbol{x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\,(\epsilon + r_t(c)), \epsilon \sim \mathcal{N}(0, I).} \ (1)$$

따라서 조건부 forward 분포는

$$\boldsymbol{q(x_t \mid x_0, c) = \mathcal{N}\left(\sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, r_t(c),\ (1-\bar{\alpha}_t) I\right)} (2)$$

가 되며, 조건 $c$에 따라 평균이 이동한다. 본 논문은 "terminal mean reference point $\mathbb{E}[x_T \mid c]$" 관점에서 shared prior의 구조적 병목을 명시적으로 해석한다.

**3**.3 Drift direction construction via Dirac/Pauli-inspired spinor parameterization

본 연구에서 drift $r_t(c)$는 reverse 단계에서의 단순 조건 주입이 아니라, forward에서 terminal noise 분포 $p(x_T \mid c)$를 조건별로 이동(tilt)시키는 평균 이동항으로 작동한다. 따라서 조건 $c$는 "라벨"이 아니라 연속적이며 스케일이 고정된(정규화된) 좌표로 설계될 필요가 있다.
이를 위해 우리는 상대론적 Dirac 동역학을 모사하려는 것이 아니라, Dirac/Pauli formalism의 핵심인 spinor의 정규화 구조와 Pauli 벡터(=Bloch representation)를 **조건** 파라미터화로 차용한다. 즉, 조건을 4-성분 실수 벡터로 표현하고, Pauli 기대값 형태로 $(s_{x'}, s_{y'}, s_z)$를 정의함으로써 **(i) $\| \mathbf{s} \| = 1$의 bounded coordinate, (ii) 1D scalar baseline**과의 자연스러운 포함 관계(z축 제한), (iii) 해석 가능한 도메인 축을 동시에 확보한다**.**

**Spinor 정의 (real 4-comp)**

**조건 $c$에 대해 4-성분 실수 벡터**

$$\boldsymbol{\psi(c) = (f_1, f_2, g_1, g_2) \in \mathbb{R}^4, \| \psi \|^2 = f_1^2 + f_2^2 + g_1^2 + g_2^2 = 1} \qquad \textbf{(3)}$$

**를 도입한다. 이는 복소 spinor $\widetilde{\psi} = (\alpha, \beta)^{\top} \in \mathbb{C}^2$의 실수 파라미터화로 볼 수 있으며,**

$$\alpha = f_1 + if_2, \beta = g_1 + ig_2 \qquad (4)$$

**로 두면 $|\alpha|^2 + |\beta|^2 = 1$을 만족한다.**

**이때 다음 두 값을 정의한다:**

$$a := |\alpha|^2 = f_1^2 + f_2^2, b := |\beta|^2 = g_1^2 + g_2^2, a + b = 1. \qquad (5)$$

**여기서 $a, b$는 "up/down" 성분의 에너지(확률질량)로 해석되며, 이후 1D baseline의 도메인 축과 직접 연결된다.**

**Pauli vector (Bloch) 구성**

**Pauli 행렬**

$$\sigma_x = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \qquad \sigma_y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix}, \qquad \sigma_z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \qquad (6)$$

**을 사용하여 Bloch 벡터를**

$$s_k := \widetilde{\psi}^{\dagger} \sigma_k \widetilde{\psi} (k \in \{x, y, z\}) \qquad (7)$$

**로 정의하면, 실수 4-성분으로 다음과 같이 쓸 수 있다:**

$$s_x = 2(f_1 g_1 + f_2 g_2), s_y = 2(f_2 g_1 - f_1 g_2), s_z = (f_1^2 + f_2^2) - (g_1^2 + g_2^2) = a - b. \qquad (8)$$

**따라서 $s_z \in [-1, 1]$이며, $s_z$는 곧 "up/down 질량차(=도메인 축)"를 나타낸다.**

### 3.3.1 Base: scalar drift (QSDD-scalar)

본 논문의 1D scalar drift(Section 3.31)는 위 Bloch 표현의 z축 성분만 사용한 제한 케이스로 해석할 수 있다.

가장 단순한 형태로 drift를 스칼라 조건 $s(c) \in [-1,1]$과 고정 방향장 $\hat{u}$로 구성한다:

$$r_t(c) = A\, C_t\, s(c)\, \hat{u}. \qquad (9)$$

$A$: drift 강도 계수이며, $x_t$를 평균 이동시키는 drift 항의 Strength를 의미한다.

$\hat{u} \in \mathbb{R}^{H \times W \times 3}$: 고정된 drift vector field 로서 이미지 픽셀에 적용될 방향 정보를 의미한다.

**재현성을 위해 본 논문에서는 "픽셀별 채널 L2 정규화"를 사용하여 $\hat{u}_{h,w,:} = \Delta_{h,w,:} / (\| \Delta_{h,w,:} \|_2 + \varepsilon)$로 정의하고, 이후 전체 스케일을 $\hat{u} \leftarrow 0.6\,\hat{u}$로 고정한다.**

$C_t \in [0,1]$는 누적 상승 항이며, T가 0~ 1000까지 상승할 때, max T= 1.0, min T에서 0.0을 만족시켜, drift의 Energy를 비선형적으로 상승시킨다.

**Anchor scalar (optional, interpolation 실험용)**

도메인 interpolation을 위해 $p \in [0,1]$을 사용한다면

$$\boldsymbol{s(c) = 2p - 1} \qquad (\mathbf{10})$$

로 매핑하여 연속 조건으로 사용할 수 있다.

### 3.3.2 Spherical path lifting with $(\sigma_x, \sigma_y, \sigma_z)$: phase-free Bloch trajectory

**Session 3.3.1**의 QSDD-1D는 $s_z = a - b$만을 사용한 z축 제한 케이스로, 도메인 축이 명확하고 해석이 단순하다는 장점이 있다. 그러나 $s_z$단일 축만으로 drift 방향을 정의하면, 중간 mixture 구간에서 drift가 직선적으로 퇴화하여(또는 특정 기저와의 상쇄로) 연속적인 변화 경로가 충분히 풍부하지 않을 수 있다.
이를 보완하기 위해 우리는 Pauli 벡터 $s = (s_x, s_y, s_z)$를 사용해 drift 방향을 3축으로 확장하되, 도메인 좌표는 여전히 $s_z$하나로 고정한다. 즉, $s_z$가 도메인 축(혼합 좌표)을 정의하고, $(s_x, s_y)$는 추가 확률 변수를 도입하지 않고 $s_z$의 결정적 함수로 정의하여, Bloch sphere 위의 연속적인 경로(trajectory)를 구성한다. 이는 **(3)–(8**)의 일반 spinor 표현 중 "상대위상/자유도"를 $\phi(s_z)$로 고정한 특정 family(phase-free lift)로 해석할 수 있다. 따라서 4-comp 정의와 모순이 아니라 '일반형 → 제한형(결정론적 리프트)'의 특수화이다.

**Deterministic lift on Bloch sphere**

**도메인 좌표 $s_z(c) \in [-1, 1]$가 주어졌을 때,**

$$\boldsymbol{\rho(c) = \sqrt{1 - s_z(c)^2}} \qquad \mathbf{(11)}$$

를 두고, 고정된 상수 $\boldsymbol{\phi_0}$또는 단순한 함수 $\boldsymbol{\phi}(\cdot)$를 사용하여

$$\boldsymbol{s_x(c) = \rho(c)\cos\,\phi(s_z(c)), s_y(c) = \rho(c)\sin\,\phi(s_z(c))} \qquad \mathbf{(12)}$$

로 정의한다. 이때 $\| s(c) \| = 1$이 항상 성립하므로, 조건 $c$는 Bloch sphere 위의 한 점으로 매핑되며, $s_z$가 변화함에 따라 구면 위의 연속적인 경로를 따라 이동한다. 중요한 점은 $\phi$가 학습되는 위상 변수가 아니라 설계된 결정적 매핑이므로, 3.3.1의 도메인 축 정합성을 유지하면서도 "구면 기하"가 제공하는 연속성과 자연스러운 보간 경로를 얻는다는 것이다.

해석 관점에서, 3.3.1은 z축 선분만을 사용한 제한 케이스였고, (12)는 그 선분을 Bloch

sphere 상의 곡선으로 리프트(lift)하여, 중간 영역에서 drift 방향이 퇴화하지 않도록 한다.

**3-axis drift composition**

데이터 기하에서 정의한 basis field $\hat{u}_x, \hat{u}_y, \hat{u}_z$에 대해,

$$\boldsymbol{\hat{u}(c) = s_x(c)\hat{u}_x + s_y(c)\hat{u}_y + s_z(c)\hat{u}_z, r_t(c) = A\,C(t)\,\hat{u}(c)} \qquad \textbf{(13)}$$

로 drift를 정의한다. 여기서 $\hat{u}_z$는 도메인 차이를 대표하는 주축이며, $\hat{u}_x, \hat{u}_y$는 z축 도메인 이동에 수반되는 구조적 변화(텍스처/형상 등)의 연속 경로를 제공하도록 설계된다. 결과적으로 QSDD는 도메인 축을 유지한 채($s_z$) Bloch sphere 기하를 통해 drift 방향의 자유도와 연속성을 부드럽게 확장한다.

### 3.4 Time schedule: cosine–$\tau$ 누적 스케줄

drift는 separation을 만들지만, 후반부의 fine detail 복원 구간에 과도하게 남아 있으면 fidelity를 훼손할 수 있다. 따라서 "초기에는 분리, 말기에는 정밀 복원"이라는 역할 분담을 위해 $C_t$를 설계한다.

drift가 시간에 따라 점진적으로 적용되도록 $C_t$를 단조 증가 누적 형태로 정의한다. 예를 들어

$$\boldsymbol{\tilde{C}(t) = \frac{1 - \cos\left(\pi(t/T)^{\tau}\right)}{2}, C_t = \frac{\sum_{k=1}^{t} \tilde{C}(k)}{\sum_{k=1}^{T} \tilde{C}(k)}}$$

로 두면 $C_t$는 $t$에 대해 단조 증가하며 $C_T = 1$이다.
(Reverse 샘플링은 $t = T \to 1$로 진행되므로, 샘플링 후반으로 갈수록 drift 영향이 약해지는 형태로 해석된다.)

### 3.5 $\eta$-target 학습 목표

drift-augmented forward에서 실제로 $x_t$를 만드는 stochastic term은 $\epsilon$이 아니라 $\epsilon + r_t(c)$이다. 그럼에도 $\epsilon$만을 타깃으로 두면, 모델은 drift를 포함한 실제 확률과 어긋난 타깃을 학습하게 되어 정합성이 깨진다. η-target은 forward 생성 과정과 학습 타깃을 일치하려 한다.

QSDD forward 정의에서

$$\boldsymbol{\eta := \epsilon + r_t(c)}$$

를 두면,

$$\boldsymbol{x_t} = \sqrt{\bar{\boldsymbol{\alpha}}_t}\boldsymbol{x_0} + \sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_t}\,\boldsymbol{\eta}$$

로 표현된다. 우리는 네트워크가 $\eta$를 직접 예측하도록 학습한다:

$$\hat{\eta}_\theta(x_t, t, c) \approx \eta, \mathcal{L}_\eta = \mathbb{E}_{t,x_0,\epsilon,c}[\| \hat{\eta}_\theta(x_t, t, c) - (\epsilon + r_t(c)) \|_2^2].$$

$$\hat{\epsilon}_\theta(x_t, t, c) \approx \hat{\eta}_\theta(x_t, t, c) - r_t(c)$$

따라서 QSDD는 $\eta$-prediction을 사용하더라도, 표준 DDPM의 $\epsilon$-prediction으로 즉시 환원되며 reverse mean 구성식을 그대로 사용할 수 있다.

이때 $c$는 (i) 스칼라 $s$또는 $p$, 혹은 (ii) spinor $\psi$로 주어질 수 있다. 본 논문에서는 $\psi$를 "예측 대상"이 아니라 **연속 조건 변수로 사용**하는 설정을 기본으로 둔다.
(보간/조합 실험에서 anchor sweep이 가능)

**3-6) Reverse Sampling**

**drift는 terminal distribution을 바꾸기 위해 도입되지만, 동시에 "그럼 표준 DDPM 이론/업데이트를 그대로 쓸 수 있나?"라는 질문을 즉시 만든다. y-world는 drift가 평행이동(translation) 이라는 점을 이용해(Jacobian 1), KL/ELBO의 핵심 항들이 표준 DDPM과 동치로 취급될 수 있음을 설명해준다. 즉 QSDD는 "새로운 sampler"를 강요하지 않고, 기존 DDPM reverse machinery와 호환되는 형태로 noise-space conditioning을 구현한다.**

**조건 drift가 들어가면 $\boldsymbol{q(x_t \mid x_0, c)}$의 평균이 이동하므로, 표준 DDPM 역과정 공식과의 정합성을 명확히 하기 위해 drift를 제거한 변수**

$$\boldsymbol{y_t} := \boldsymbol{x_t} - \sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_t}\,\boldsymbol{r_t(c)}$$

**를 정의한다. 그러면**

$$\boldsymbol{y_t} = \sqrt{\bar{\boldsymbol{\alpha}}_t}\boldsymbol{x_0} + \sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_t}\,\boldsymbol{\epsilon}$$

**가 되어 표준 DDPM world와 동일한 형태가 된다. 따라서 reverse는 $y$-world에서 표준 DDPM 업데이트를 수행한 뒤,**

$$\boldsymbol{x_{t-1}} = \boldsymbol{y_{t-1}} + \sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_{t-1}}\,\boldsymbol{r_{t-1}(c)}$$

**로 원래 변수로 되돌린다. (정확한 $\boldsymbol{\mu_\theta, \sigma_t}$구성 및 알고리즘은 Appendix에 기술)**

**Experiments (Method까지 완성했고 Experiments와 Appendix는 지속적으로 추가시키겠습니다. 아래에 있는 이미지가 카톡으로 말씀드린 FID 150 vs 99 정도의 값으로 나온 이미지 샘플 중 일부를 발췌한것입니다.)**

**(figure 0. A=0 50K 학습 VS A=2 50K학습 차이점)**

**drift를 제외한 모든 상황 동일시 된 훈련 스텝(50K)에서도**, drift 항을 포함한 QSDD(A=2)는 조건부 DDPM(A=0)과 **질적으로 상이한 샘플링 궤적을 관찰한다**.
이러한 초기 단계에서의 발산은, drift 항이 학습된 의미 embedding에 명시적으로 의존하지 않고, **x_t의 확률 흐름 자체를 재구성함으로써** 내재적인 조건화 메커니즘으로 작용함을 시사한다.

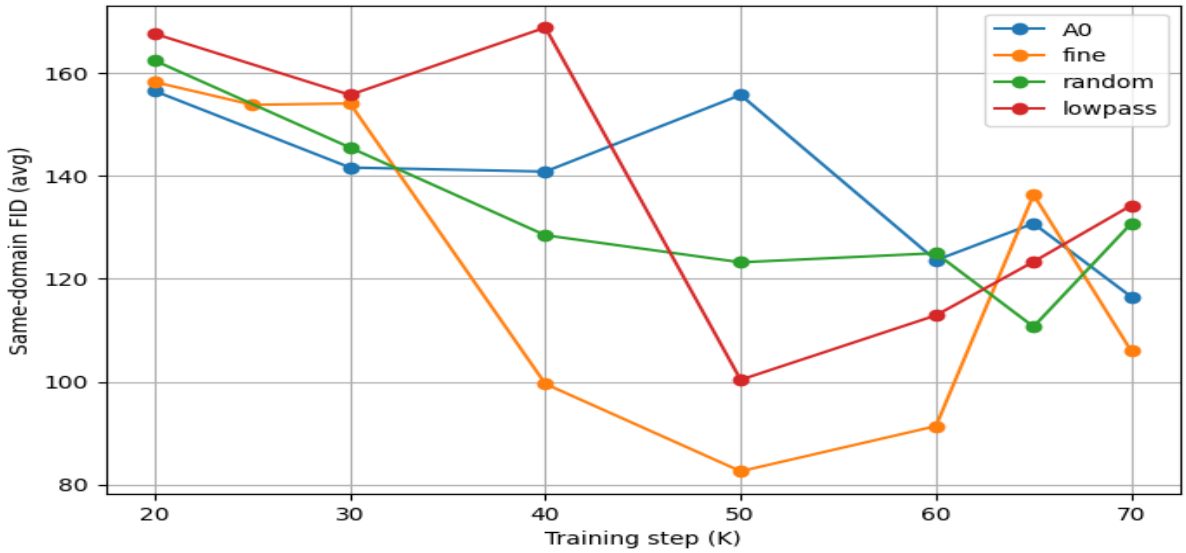


**(figure 1.real vs Gen Image Average FID Graph)**

**위 5가지 지표를 학습 step에 따라 변화되는 (FID/KID/Cross-Domain FID) 수치 비교**

***(Cross-Domain FID = flower 생성 이미지 & leaf real image FID 비교 + leaf 생성 이미지 & flower real image FID 비교) (코드 구현 완료)**

**FID는 5K 간격으로 55K까지 테이블 생성**

**마지막으로 FID or KID Curve 그래프를 그리며 최적 모델 구조 선정 (코드 구현 완료)**

## 2. 1번에서 선정된 모델 구조로 A sweep(Drift 계수 비교 실험)

**A= {0.5 , 0.8 , 1.1 ,1.4 ,1.7, 2.5}** 1번에서 FID Curve를 통해 구한 최적 학습 step을 기준으로 step -5k | step | step+5k 에서 최적 FID/KID/Cross-Domain FID 비교.

## 3. 2번에서 선정된 A 최적 drift 계수를 통한 최종 비교

2번에서 선정한 최적의 Time step + A drift 계수를 가진 모델을 비교

A=0 (Conditional Diffusion model) vs A* (QSDD) vs Shift-DDPM(best Scale)

Image 2000장씩 FID KID Cross-DOMAIN 비교

마지막으로, 2D- separation & trajectory (t=100,300,500,700,900) 비교 (QSDD vs A=0)

## 4. Celeb-A (Male vs Female)을 통한 유사한 도메인 분리성 확인

256 x256 size Celeb-A 이미지를 도메인 분리 하여, 2번의 결과를 통한 이미지 생성

위 결과와 dirac-방식을 통해 완성된 자유도 확장 방식으로 이미지 생성

2 방식에서 FID KID Cross-Domain FID 비교.

## 5.Interpolate 가능성 확인

discrete 방식의 scalar spin또한, spin_up {0.9,0.93,0.97,1.0}로 anchor 형태로 학습
(spin_down은 1-p의 형태로 이루어진다.)
dirac 방식도 2p-1을 이용하여, anchor 형태로 학습하여 interpolate 비교
p=0.0 0.3 0.5 0.7 1.0 5개를 비교하는 이미지 나열

## Conclusion(아직 쓰기 이전)

## Appendix

**1.왜 Cos-Tau 형태를 300step 이후에 거의 drift가 최소화 되게 가져가는가? 700~300step에서 기하급수적으로 값이 줄어들어, 0~300step까지 drift의 영향 없이 세밀한 복원력을 위해 비선형적 구조로 누적시켰습니다.)**

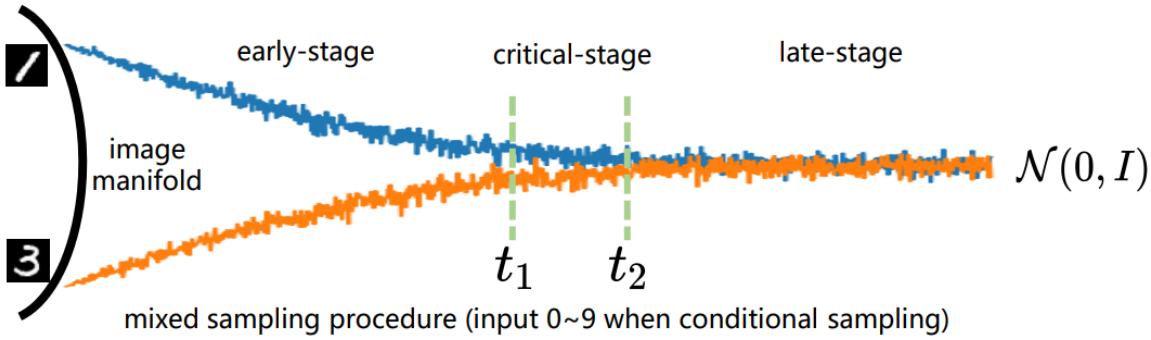


**(*위 사진은 Shift-DDPM의 이미지 복원 상태에 대한 스텝별 분리성이다. Early-stage에 해당하는 30%정도의 step에서는 이미 경로가 갈라져있다.**

위 drift는 누적항으로 CT=1이 되게 만족하여, 각 t step별로 drift가 무작위적으로 움직이는 것이 아닌, 비선형적으로 T=1000일 때 까지 누적 증가하다가 T=300 부터는 매우 약하게 움직임을 보일 것이다.

**2.Reverse sampling: DDPM-equivalent world:**

조건 $c$가 주어졌을 때의 생성모형:

$$\boldsymbol{p_\theta(x_{0:T} \mid c) = p(x_T) \prod_{t=1}^{T} p_\theta\,(x_{t-1} \mid x_t, c)}$$

근사 posterior(=forward chain):

$$\boldsymbol{q(x_{1:T} \mid x_0, c) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}, c)}$$

***So, DDPM에서 주요적으로 주장한 KL 발산 식:***

$$\boxed{\mathcal{L} = \mathbb{E}_q\Big[D_{KL}\big(q(x_T \mid x_0, c) \parallel p(x_T)\big) + \sum_{t=2}^{T} D_{KL}\big(q(x_{t-1} \mid x_t, x_0, c) \parallel p_\theta(x_{t-1} \mid x_t, c)\big) - \log p_\theta(x_0 \mid x_1, c)\Big].}$$

**$y_t$-world에서의 동치: "QSDD는 DDPM과 같은 형태로 학습 가능"**

이제 각 KL 항이 $y$-world에서 DDPM과 동치임을 보인다.

A.4.1 KL 불변성(평행이동/가역변환에 대한 불변)

가역변환 $T$에 대해 KL은 불변이다:

$$\boldsymbol{D_{KL}(q(z) \parallel p(z)) = D_{KL}(q_T(u) \parallel p_T(u)), u = T(z),}$$

여기서 $q_T(u) = q(T^{-1}(u)) \mid \det J_{T^{-1}} \mid$, $p_T$도 동일.
본 논문에서 $T$는 평행이동 $y_t = x_t - \sqrt{1-\bar{\alpha}_t} r_t(c)$이며 Jacobian이 1이므로,

- $x_t$에서의 KL 항들은
- 동일한 shift가 적용된 $y_t$에서도 값이 동일하다.

A.4.2 Terminal KL 항 동치

$$\boldsymbol{q(x_T \mid x_0, c) = \mathcal{N}(\sqrt{\bar{\alpha}_T} x_0 + \sqrt{1-\bar{\alpha}_T} r_T(c),\ (1-\bar{\alpha}_T) I)}$$

이고,

$$\boldsymbol{y_T = x_T - \sqrt{1-\bar{\alpha}_T} r_T(c) \Rightarrow q(y_T \mid x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_T} x_0, (1-\bar{\alpha}_T) I).}$$

**따라서**

$$\boldsymbol{D_{KL}(q(x_T \mid x_0, c) \parallel p(x_T))}$$

**는 $y_T$-world에서의 대응 prior $p(y_T)$를 두면(예: N(0,I)$\mathcal{N}(0, I)$) 표준 DDPM terminal KL과 동일하게 취급된다.**

QSDD에서는

$$\boldsymbol{\eta :\approx \epsilon + r_t(c)}$$

네트워크가 $\hat{\boldsymbol{\eta}}_{\boldsymbol{\theta}}(\boldsymbol{x}_t, \boldsymbol{t}, \boldsymbol{c}) \approx \boldsymbol{\eta}$를 예측한다.

$y$-world로 가면

$$\boldsymbol{y}_t = \boldsymbol{x}_t - \sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_t}\boldsymbol{r}_t(\boldsymbol{c}) \approx \sqrt{\bar{\boldsymbol{\alpha}}_t}\boldsymbol{x}_0 + \sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_t}\boldsymbol{\epsilon},$$

즉 표준 DDPM의 $\boldsymbol{\epsilon}$이 존재한다. 따라서

$$\boldsymbol{\epsilon} = \boldsymbol{\eta} - \boldsymbol{r}_t(\boldsymbol{c}), \hat{\boldsymbol{\epsilon}}_{\boldsymbol{\theta}} \approx \hat{\boldsymbol{\eta}}_{\boldsymbol{\theta}} - \boldsymbol{r}_t(\boldsymbol{c})$$

**로 변환되며, 표준 DDPM의 mean 구성식을 그대로 쓸 수 있다.**

**예를 들어 DDPM에서 흔히 쓰는**

$$\boldsymbol{\mu}_{\boldsymbol{\theta}}(\boldsymbol{y}_t, \boldsymbol{t}) = \frac{\boldsymbol{1}}{\sqrt{\boldsymbol{\alpha}_t}}(\boldsymbol{y}_t - \frac{\boldsymbol{\beta}_t}{\sqrt{\boldsymbol{1} - \bar{\boldsymbol{\alpha}}_t}}\hat{\boldsymbol{\epsilon}}_{\boldsymbol{\theta}}(\boldsymbol{y}_t, \boldsymbol{t}, \boldsymbol{c}))$$

**로 구성되어, KL 발산식을 DDPM과 같이 구성한다.**

## 3. Dirac inspired Extension Exact Method

- $\boldsymbol{p}_{\uparrow} > \boldsymbol{0.9}$**→ spin-up →** ***Celeb-A (Male Face Feature) (DOMAIN A)***
- $\boldsymbol{p}_{\downarrow} > \boldsymbol{0.9}$**→ spin-down →** ***Celeb-A(Female Face Feature) (DOMAIN B)}***

$$\boldsymbol{s}_x = \boldsymbol{2}(\boldsymbol{f}_1\boldsymbol{g}_1 + \boldsymbol{f}_2\boldsymbol{g}_2),$$

$$\boldsymbol{sy} = \boldsymbol{2}(\boldsymbol{f1g2} - \boldsymbol{f2g1}),$$

$$\boldsymbol{s}_z = \boldsymbol{f}_1^2 + \boldsymbol{f}_2^2 - \boldsymbol{g}_1^2 - \boldsymbol{g}_2^2.$$

**즉,**

- $\boldsymbol{s}_z$**는 "domain up/down 비율"의 차이**
- $\boldsymbol{s}_x, \boldsymbol{s}_y$**는 파동함수의 위상 차이와 성분 혼합에서 솟아남**
  **데이터(예: 남자얼굴 vs여자얼굴)의 low-pass prototype mean을 각각** $\boldsymbol{\mu}_{\text{up}}, \boldsymbol{\mu}_{\text{down}}$**이라 하면:**
  - **(1) 도메인 축 (z축)**
  - $\boldsymbol{u}^z = \boldsymbol{\mu}_{\text{up}} - \boldsymbol{\mu}_{\text{down}}$.
  - **→ 남자와 여자의 얼굴 특징의 주된 차이 방향을 나타냄. (실험 결과에 의해 random u^가 될 수 있음.)**
  - **(2) 세로 구조 축 (x축)**

- $\boldsymbol{u^x(h,w,c)} \propto (\boldsymbol{\mu}_{\text{up}} - \boldsymbol{\mu}_{\text{down}})(\boldsymbol{h,w,c}) - (\boldsymbol{\mu}_{\text{up}} - \boldsymbol{\mu}_{\text{down}})(\boldsymbol{h-1,w,c})$.
- **(3) 가로 구조 축 (y축)**
- $\boldsymbol{u^y(h,w,c)} \propto (\boldsymbol{\mu}_{\text{up}} - \boldsymbol{\mu}_{\text{down}})(\boldsymbol{h,w,c}) - (\boldsymbol{\mu}_{\text{up}} - \boldsymbol{\mu}_{\text{down}})(\boldsymbol{h,w-1,c})$.

- **이 세 개의 tensor는 모두**
- $\boldsymbol{u^x, u^y, u^z} \in \mathbb{R}^{\boldsymbol{H \times W \times 3}}$.
- **즉, 데이터 기하(data geometry)의 3개 축을 정의한 것**